Instituto Técnico Profesional de Costa Rica

Especialización ciencia de datos

Módulo 6 – Proyecto integrador de Análisis de datos

Alcance del proyecto

Prof. Bayron Alexander Vargas Redondo

Grupo: 4

Integrantes:

Daniel J Reyes

Luis Felipe Rodriguez Arce

Angeline Sandoval Arguedas

Derinia Zhang Gu

2026

Alcance del proyecto

1. Información del Equipo

Para el desarrollo de este proyecto, se ideó una consultora con los siguientes roles:

- **Nombre del equipo consultor:** DERI - Solutions
- **Integrantes y roles propuestos:**
    - **Data Engineer:** Responsable del modelado, limpieza de datos y creación de la variable calculada
        - Encargado del puesto: Daniel J.Reyes
    - **Data Analyst:** Encargado de auditar el comportamiento de los datos, identificar patrones de cuellos de botella y construir los modelos analíticos.
        - Encargado del puesto: Derinia Zhang Gu
    - **Business Translator / Project Lead:** Encargado de alinear los hallazgos técnicos con las métricas de negocio, definir los SLA por orden de prioridad y estructurar el dashboard final en Power BI.
        - Encargados del puesto: Luis Felipe Rodríguez Arce y Angeline Sandoval Arguedas

2. Contexto del Negocio

- **Industria o sector del proyecto:** Comercio Minorista enfocado Logística de Cadena de Suministro
- **Descripción de la empresa: Superstore**, una cadena minorista que comercializa suministros de oficina, mobiliario y tecnología a nivel global. La empresa opera bajo un modelo multicanal donde los clientes eligen diferentes niveles de servicio de envíos pagando tarifas diferenciadas por cada uno.

3. Planteamiento del Problema

- **Dolor principal u oportunidad de mejora:** La gerencia de operaciones de Superstore desconoce si la bodega está despachando los paquetes dentro de los tiempos de preparación, es decir, se desconoce el tiempo de procesamiento según el método de envío pagado por el cliente. Actualmente, no existe una medición centralizada del tiempo transcurrido entre la fecha en que se realizó

la orden, siendo esta Order Date, y la salida de la orden del almacén, siendo esta Ship Date, lo que genera posibles violaciones de Acuerdos de Nivel de Servicio, siendo estos SLA, y la posible generación de cuellos de botella operativos concentrados en ciertas regiones geográficas o categorías de productos de difícil manejo.

4. Objetivos

Objetivo General

- Evaluar la eficiencia del proceso de despacho en bodega mediante el cálculo y análisis de los días de procesamiento, identificando desviaciones frente a los tiempos estimados por tipo de envío y detectando cuellos de botella por orden de prioridad y categoría.

Objetivos Específicos

- Crear la variable calculada Días de Procesamiento = Ship Date - Order Date.
- Medir el porcentaje de cumplimiento e incumplimiento de tiempos de despacho según la orden de prioridad seleccionada. Ejemplo: Crítico. Alto, Medio y Baja.
- Identificar cuáles son los mercados y categorías de producto con mayor tiempo promedio de procesamiento o mayor tasa de retraso.
- Analizar si los retrasos se concentran en pedidos de alto valor o alto volumen.

5. Fuentes de Datos (Data Sourcing)

- **Enlace al dataset seleccionado:** Kaggle - Superstore Sales Analytics

  https://www.kaggle.com/datasets/thuandao/superstore-sales-analytics

- **Descripción de los datos**: Consiste en 1 archivo plano / tabla plana en formato CSV, con un volumen aproximado de 51291 filas de registros de venta y 21 columnas con información transaccional, geográfica y de producto.
- **3 variables principales:**

  1. Order Date / Ship Date: Fechas de compra y de despacho en bodega.
  2. Order priority: Método de envío pagado.
  3. Market / Category: Mercado y clasificación del producto.

6. Definición de Variables y KPIs

KPI 1: Tiempo Promedio de Procesamiento, es decir Processing Time

Fórmula: Días de Procesamiento = Fecha de Envío (Ship Date) - Fecha de Pedido (Order Date)

Métrica: Promedio y Mediana de días por pedido.

Propósito: Establecer la línea base de velocidad operativa en bodega.

KPI 2: Tasa de Cumplimiento de SLA es decir % On-Time Shipping

Fórmula: (Pedidos Despachados a Tiempo / Total de Pedidos) * 100

Criterio de SLA asumido según order priority - limitaciones:

Crítico: 0 días (despacho el mismo día)

Alto: 2 días

Medio: 4 días

Bajo: 6 días

Propósito: Determinar el nivel de cumplimiento del compromiso con el cliente.

KPI 3: Tasa de Retraso Crítico (% Late Shipments)

Fórmula: (Pedidos Fuera de SLA / Total de Pedidos) * 100

Propósito: Medir la magnitud del fallo operativo.

KPI 4: Índice de Cuello de Botella Regional y por Categoría

Métrica: Tiempo promedio de despacho desglosado por mercado.

Propósito: Identificar los centros logísticos o líneas de producto con peor desempeño.

Arquitectura y tratamiento de datos

1. Diccionario de Datos Final

Columna	Descripción	Tipo de dato	Ejemplo
order_id	Identificador de un pedido. Un pedido puede tener varias filas (una por producto).	Alfanuméricos (string)	AG-2011-2040
order_date	Fecha en que se realizó el pedido.	Fecha	01/01/2011
ship_date	Fecha en que se envió el pedido.	Fecha	06/01/2011
ship_mode	Modalidad de envío.	Alfanuméricos (string)	Standard Class
customer_name	Nombre completo del cliente.	Alfanuméricos (string)	Toby Braunhardt
segment	Segmento de cliente.	Alfanuméricos (string)	Consumer
state	Estado, provincia o departamento del envío.	Alfanuméricos (string)	Constantine
country	País de destino del pedido.	Alfanuméricos (string)	Algeria
market	Mercado comercial al que pertenece el país.	Alfanuméricos (string)	Africa
region	Región geográfica, más detallada que	Alfanuméricos (string)	Africa

	market.		
product_id	Identificador del producto.	Alfanuméricos (string)	OFF-TEN-10000025
category	Categoría principal del producto.	Alfanuméricos (string)	Office Supplies
sub_category	Subcategoría del producto.	Alfanuméricos (string)	Storage
product_name	Nombre descriptivo del producto.	Alfanuméricos (string)	Tenex Lockers, Blue
sales	Importe de la venta de la línea de pedido.	Numérico	408
quantity	Unidades vendidas en la línea.	Numérico	2
discount	Descuento aplicado como fracción del precio.	Numérico	0
profit	Beneficio de la línea (puede ser pérdida).	Numérico	106.14
shipping_cost	Costo de envío de la línea.	Numérico	36.46
order_priority	Prioridad del pedido.	Alfanuméricos (string)	Medium
year	Año del pedido.	Numérico	2011
process_time	Cantidad de días que un pedido es creado hasta que es enviado (Columna calculada)	Numérico	4

2. Reglas de limpieza y transformación (Data Lineage)

Limpieza / Tratamiento	Acción ejecutada	Valor tratado
Limpieza de nombres	Se estandarizaron los nombres de las columnas mediante minúsculas, guiones y la eliminación de símbolos o caracteres.	Todas
Limpieza de textos	Se eliminaron espacios de las columnas de texto y se estandarizó el formato escrito.	Columnas: country, state y customer_name
Estandarizar categórica	Se corrigieron los errores ortográficos y se unificaron las categorías.	Columnas: category y sub_category
Variables numéricas	Se removieron símbolos, espacios y comas y se convirtieron en valores numéricos. Corrección de valores negativos.	Columnas: sales, quantity, discount, profit, shipping_cost y year
Valores nulos	Reemplazar los valores que representan “vacío” por Nan	Columnas: sales, quality, discount, profit, shipping cost y year.
Corrección de fechas	Se convirtió los valores de texto a formato de fecha estándar	Columnas: order_date y ship_date
Control de duplicados	Se mantuvieron debido a que cada fila de la columna correspondía a ventas legítimas.	Columna: order_id

Bifurcación	Permite conservar la trazabilidad de los registros con información atípica sin mezclarlos con el CSV original cargado para el análisis.	Columna: process_time, order_priority
Corrección tipo de datos	Se corrigen los valores a su tipo de dato correspondiente	Columnas : ● **Int:** quantity, year, sales y process_time ● **Float:** discount, profit, shipping cost ● **String:** ship_mode, segment, order_id, order_priority, customer_name, state, region, country, market. product_id, category, sub_category y product_name ● **Datetime:** order_date y ship_date

3. Modelo de Datos Final

El modelo de datos utilizado corresponde a un modelo de tabla plana, en la cual la información necesaria para realizar el análisis del proceso de despacho se encuentra concentrada en una única tabla.

La granularidad del modelo se encuentra definida a un nivel de pedido, debido a que cada fila corresponde a un pedido individual realizado por un cliente. Cada registro contiene un valor por cada variable a analizar e información pertinente a un pedido en específico y permitiendo realizar un análisis sobre el proceso de despacho del negocio.

Con respecto a la realización de joins o cruces entre tablas sobre el modelo, estos no se realizaron debido a que originalmente todos los datos provinieron de una única tabla plana, y debido a que en esta misma tabla se posee toda la información del negocio necesaria para el análisis de la eficiencia del proceso de despacho, no se vio necesario incorporar o unificar con otras tablas o fuentes de datos.

En consecuencia, el modelo de datos es simple y centralizado permitiendo su uso directo para lo que corresponde el proceso de tratamiento y análisis con respecto a las necesidades del negocio.

4. Normas establecidas

a. Norma 1

Debido a la simplicidad del modelo, se decidió establecer una limitación con respecto a la columna de order_priority, al asignar cada valor por un equivalente numérico con mencionar que es el tiempo máximo de despacho si excede se denomina como producto que va en proceso de atraso, de los cuales son los siguientes:

- **Critico:** 0 días
- **Alto:** 2 días
- **Mediano:** 4 días
- **Bajo:** 6 días

La razón de la definición de estas limitaciones es establecer una normativa que permita analizar la eficiencia de despacho del negocio de manera más objetiva.

b. Norma 2

Se modificó la base de datos principal, agregando modificaciones sin dañar su estructura principal con el fin de ensuciarla y ejecutar un proceso de limpieza de base de datos con python más profundo.

Análisis Exploratorio de Datos - EDA

1. Patrones iniciales

Inversión crítica del modelo de servicio: La operación registra un incumplimiento sistemático con un 60,92% de despachos fuera de SLA. El esquema de prioridades funciona en sentido inverso a la promesa comercial: las órdenes "Crítico" (SLA de 0 días) sufren el mayor atraso operativo, excediendo su límite en un promedio de 1.5 a 2.25 días. En cambio, los pedidos "Low" muestran el menor desfase

Desfase entre la meta y la velocidad real: La preparación recurrente en bodega (mediana) confirma un desfase constante frente a los compromisos de entrega:

- Crítico: Toma 2 días despachar (SLA: 0 días).
- Alto: Toma 4 días despachar (SLA: 2 días).
- Medio: Toma 5 días despachar (SLA: 4 días).
- Bajo: Toma 6 días despachar (cumple su SLA).

Otro patrón inicial con los tiempos de procesamiento de los pedidos según su prioridad del negocio, se identificó que la cantidad de tiempo central de todos los pedidos, el cual indica que la mitad de los tiempos de procesamiento se encuentran por encima o debajo de este valor, y el valor por cada prioridad es el siguiente:

- Critico: 2 días
- Alto: 4 días
- Medio: 5 días
- Bajo: 6 días

Junto a lo anterior, cada prioridad posee una demarcación que permiten agrupar el 50% de los pedidos por su prioridad, lo cual indica que para cada prioridad la mitad de los datos se encuentran dentro de este rango de días de procesamiento, en este caso son las siguientes:

- Crítico: Q1: 1 días y Q3: 3 días
- Alto: Q1: 2 días y Q3: 4 días
- Medio: Q1: 4 días y Q3: 5 días
- Bajo: Q1: 6 días y Q3: 7 días

Además de eso cada prioridad posee límites objetivos las cuales permiten identificar un pedido como normal y no una anomalía, y representan la otra mitad de los pedidos por su prioridad, en el caso de cada prioridad los límites son los siguientes:

- Critico: Limite inferior - 0 a 1 días, Limite superior: 3 a 3
- Alto: Limite inferior - 0 a 2 días, Limite superior: 4 a 5
- Medio: Limite inferior - 3 a 4 días, Limite superior: 5 a 6

- Bajo: Límite inferior - 6 a 6 días, Límite superior: 7 a 7

Con lo todo lo anterior, se puede destacar cuánto tiempo los pedidos son entregados habitualmente por el negocio, y cómo estos se van concentrando dependiendo de su prioridad, además de poder identificar pedidos fuera de lo normal fácilmente.

Se logró identificar por medio de un análisis de Pareto los países que tienen mayor peso dentro de las operaciones de Superstore siendo 29 países los que concentran el 80% de los pedidos. Lo que permite tener una mejor noción del mercado y actuar conforme a ello.

2. Tendencias

La tendencia principal que podemos destacar es que siempre es de crecimiento constante entre los order priority teniendo tendencia de crecimiento de 5,2 de pedidos en low hasta 53,1% en medium dándonos a entender que esto sigue creciendo a través del tiempo, pero siendo constante en su crecimiento sin tener picos de crecimientos.

3. Anomalías

Se identificó que el volumen de pedidos se concentran principalmente en la categoría de Office Supplies siendo un 61,1%, por otro lado, las categorías de Technology y Furniture presentan un comportamiento similar cercano al 20% cada una.

En cuanto al comportamiento de mercado por países. Estados Unidos representa la mayor concentración de pedidos con un 19,5%. Mientras que Australia, Francia, México representan alrededor del 16.1% de participación en conjunto. Por otro lado, el 34.8% es la suma de otros países que hacen pedidos a baja escala, lo que permite contrastar la principal concentración por país y diversificación de participación geográfica.

4. Variables de mayor impacto para el negocio

El sector de tecnología representa una amenaza crítica para la rentabilidad y la retención de clientes. Con un Ganancia acumulado de 37,177 y demoras que alcanzan los 4 días, esta categoría se encuentra en el epicentro de la zona de alto riesgo. Este nivel de atraso no solo compromete el valor financiero generado, sino que expone directamente a la compañía a una alta tasa de cancelaciones, pérdida de confianza y devoluciones masivas de dinero.

Por su parte, las demás líneas de negocio operan en un margen de riesgo más controlado pero urgente:

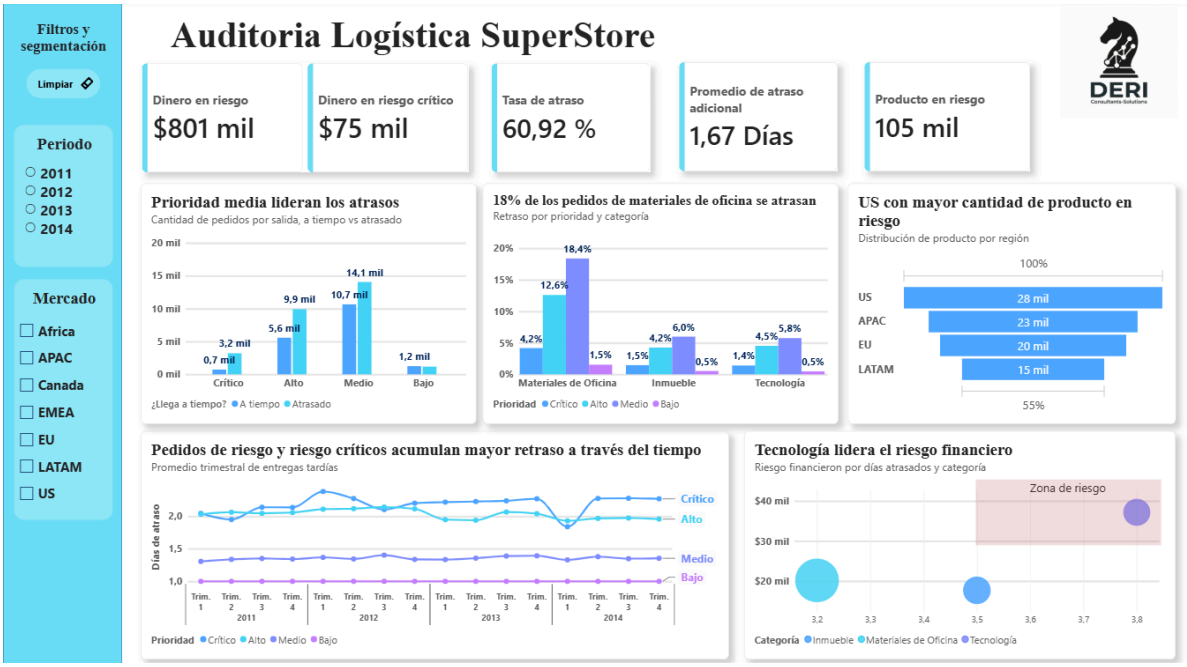
- Materiales de oficina: Se mantiene en niveles de retraso menores, respaldado por un Ganancia de 20,182.

- Inmueble: Registra un Ganancia de 17,703 con un retraso de 3.5 días, manteniéndose fuera de la zona roja de mayor peligrosidad.

Teniendo un margen de riesgo total de 75062 dólares de que si no se ataca rápidamente hay un riesgo de perder ese dinero. Además estamos teniendo 60,92% de retrasos críticos.

Visualización y Business Intelligence

Vistas del dashboard



Insights (alineados a los objetivos y KPI´s)

KPIs

KPI - Dinero en riesgo: Este el dinero según la prioridad de orden (orden priority) que esta en rangos que esta en la normalidad del negocio pero en su valor económico de la empresa en las ganancias,osea que son tiempo que acontecen pero es lo habitual de los retrasos pero con su sumatoria en valor económico.

KPI - Dinero en riesgo crítico: Es la representación económica de la sumatoria de los valores de profit que está según los valores atípicos de la orden de prioridad que está atrasada.

KPI - Total de atraso: Permite identificar el porcentaje de pedidos que tengan una condición de atraso en condiciones generales, determinado por las normas establecidas anteriormente.

KPI - Promedio de atraso adicional: Permite identificar cuántos días en promedio se están atrasando los pedidos.

KPI - Producto en riego: Permite identificar el riesgo de atrasos en función a las unidades de producto.

KPI – Retraso Operativo por Prioridad: Este indicador permite evaluar cuánto se excede el SLA según la prioridad del pedido, mostrando si la operación está cumpliendo o fallando en los tiempos prometidos al cliente.

Gráficas

Gráfica 1 - Barra vertical agrupadas por 2: Esta gráfica se alinea al KPI 2 y KPI 3, puesto a que el total de cumplimiento o incumplimiento de los pedidos. Lo que permite visualizar el compromiso con el cliente y la magnitud del fallo operacional, distinguido por la prioridad de las órdenes.

Gráfica 2 - Barra vertical agrupada por 4: Se alinea con el KPI 2 y KPI 3, debido a que permite distinguir el nivel de cumplimiento del SLA, centralizado por su prioridad y por la categoría de los productos del pedido. Lo que permite resaltar el nivel de cumplimiento y compromiso que se tiene con el cliente y el nivel de fallo que se presenta por prioridad y por categoría.

Gráfico 3 - Embudo: Se alinea al KPI 4 que indica el mercado que presenta cuellos de botella y también, al KPI de producto en riesgo. Lo que permite visualizar el mercado crítico y las unidades de producto en riesgo.

Gráfico – Pedidos de riesgo y riesgo crítico acumulan mayor retraso a través del tiempo

El gráfico muestra que las prioridades Crítico y Alto concentran el mayor nivel de retraso acumulado conforme avanzan los trimestres, reflejando un incumplimiento constante del SLA. La prioridad Medium también presenta retraso sostenido, aunque en menor proporción, mientras que Bajo es la única categoría que mantiene un comportamiento estable y alineado al tiempo esperado. En conjunto, el gráfico evidencia que las prioridades que deberían despacharse con mayor rapidez son las que más retraso acumulan, mientras que la prioridad más urgente es la única que opera dentro del tiempo comprometido, reflejando directamente el comportamiento medido por el KPI.

Gráfico 4 - Tecnología lidera el riesgo financiero:

El gráfico muestra la situación actual de riesgo según las categorías, las ganancias y el tiempo de atraso. En este, el tamaño de los círculos representa el volumen de producto atrasado; el eje X, el tiempo de retraso; las categorías se diferencian por el color de los círculos; y el eje Y representa la ganancia, reflejando la economía en riesgo crítico. El objetivo del gráfico es demostrar que Tecnología es la categoría que requiere una solución urgente por encontrarse en la zona de riesgo. La siguiente categoría a resolver por orden de importancia es la de materiales de oficina, debido al tamaño y volumen de sus productos en riesgo y su impacto en la economía.

Recomendaciones

La recomendación y resolución presentadas corresponden a una propuesta enfocada en la gestión de riesgo crítico. En esta se especifica la región, categoría y prioridad de orden desde las cuales se debe iniciar la mejora del proceso de optimización logística.

De manera prioritaria, se sugiere intervenir la Región de Estados Unidos, específicamente en la categoría de Tecnología y con prioridad de orden Crítico. Esto se debe a que la prioridad de orden Crítico registra la constante más alta de pedidos atrasados, Estados Unidos es la región con mayor acumulación de órdenes pendientes y Tecnología representa el mayor margen de riesgo crítico económico para el negocio, alcanzando los $37,177.

Adicionalmente, se recomienda continuar posteriormente con el área de Materiales de Oficina. Aunque esta categoría concentra la mayor cantidad de productos en riesgo crítico 3,918 unidades, representa el segundo impacto económico más alto por categoría, equivalente a $20,182, además continuando con los mismos otros parámetros de Región y Crítico.